

Segmentación No Supervisada de Alojamientos de Airbnb de la Ciudad de México.

Hoy en día, las organizaciones manejan volúmenes de información tan masivos que las herramientas tradicionales de análisis resultan insuficientes. Para extraer valor de esta información se recurre al *Machine Learning* (Aprendizaje Automático), una rama de la inteligencia artificial centrada en algoritmos capaces de aprender de patrones en datos históricos para realizar predicciones sobre nuevos datos [1].

Dentro de este campo, una de las técnicas fundamentales es el aprendizaje no supervisado. En este enfoque, se proporciona al algoritmo un conjunto de datos sin etiquetar, lo que significa que no existe un resultado correcto predefinido que el modelo deba aprender a predecir. En su lugar, su objetivo principal es explorar los datos de manera autónoma para descubrir estructuras ocultas, patrones intrínsecos o agrupaciones naturales (segmentos) entre las observaciones. Dentro de esta rama, destacan dos grandes familias de algoritmos: los de agrupamiento o *clustering* (tales como K-Means, Modelos de Mezcla Gaussiana o GMM, Clúster Jerárquico y DBSCAN), cuya finalidad es agrupar elementos similares con base en su distancia, densidad o probabilidad; y las técnicas de reducción de dimensionalidad (como el Análisis de Componentes Principales o PCA), empleadas para simplificar conjuntos de datos altamente complejos preservando su varianza e información más relevante [2].

La finalidad principal de este proyecto es construir un modelo de aprendizaje no supervisado cuya función sea agrupar alojamientos de Airbnb de la Ciudad de México, con base en características clave como la ubicación, el tipo de propiedad y las amenidades ofrecidas, entre otras.

El flujo de trabajo se dividirá en las siguientes fases:

- **Limpieza y Análisis Exploratorio de Datos (EDA):** Comprensión de las distribuciones, tratamiento de valores atípicos e imputación de valores nulos.
- **Reducción de dimensiones (PCA):** Reducción del número de componentes óptimos para explicar el 95 % de la varianza.
- **Determinar número óptimo de clústers:** Aplicación de cuatro algoritmos no supervisados (K-Means, Gaussian Mixture Model, Clúster Jerárquico y DBSCAN).
- **Visualización en baja dimensionalidad:** Visualización 2D del número de clústeres óptimos por modelos.
- **Perfilamiento:** Caracterización y Conclusiones por grupo.
- **Recomendaciones de Negocio:** Conclusiones y estrategias comerciales para cada clúster.

Conjunto de Datos

En este proyecto se utiliza el conjunto de datos de Inside Airbnb, el cual recopila información pública de la plataforma de alojamiento Airbnb con el objetivo de analizar el comportamiento e impacto de los alojamientos en distintas ciudades. Entre sus aplicaciones más comunes se encuentran el análisis de precios de renta, la evaluación de la oferta y la demanda, así como el estudio de su influencia en el mercado inmobiliario.

El dataset analizado en este documento corresponde a los alojamientos de Airbnb en la Ciudad de México. Está conformado por cuatro archivos: *listings.csv*, *reviews.csv*, *calendar.csv* y *neighbourhoods.geojson*. El archivo *listings.csv* contiene la información principal de los alojamientos y es el utilizado en el presente análisis. Por otro lado, *reviews.csv* incluye información textual y temporal de las reseñas, *calendar.csv* contiene la disponibilidad y precios por día, y *neighbourhoods.geojson* proporciona la delimitación geográfica en formato geojson.

El conjunto de datos puede consultarse en el siguiente enlace: <https://insideairbnb.com/get-the-data/>. La versión empleada en el presente documento es la de septiembre de 2025.

Algunas de las características incluidas en el archivo *listings.csv* son las siguientes:

- **Información del anuncio**

- id, name, description

- **Información del anfitrión**

- host_id, host_name
- host_listings_count
- host_response_rate

- **Ubicación**

- neighbourhood
- (latitude, longitude)

- **Características del alojamiento**

- room_type
- accommodates
- bathrooms
- bedrooms
- beds

- **Precio**

- **Calificaciones**

En la sección **Procesamiento de Datos** se describe la metodología empleada para la depuración y selección de variables, mediante la cual se redujo el conjunto inicial hasta un total de 54 columnas, que posteriormente se utilizan para el análisis exploratorio de datos. Si desea consultar el diccionario de datos de las 54 variables empleadas en este documento, se recomienda ir a la sección **Anexos**.

Procesamiento de Datos

Como parte de esta etapa, para el dataset listings se eliminaron columnas con varianza nula, identificadores, etiquetas irrelevantes, descripciones textuales y variables de tipo fecha. Algunas de las columnas removidas del dataframe incluyen: *scrape_id*, *neighbourhood_group_cleansed*, *listing_url*, *picture_url*, *host_since*, *id*, entre otras.

Adicionalmente, se exploraron los conjuntos de datos *calendar.csv* y *reviews.csv* a los cuales se les realizó una agrupación con el objetivo de obtener tablas agrupadas por id con métricas calculadas como *first_review_date*, *last_review_date*, *n_reviews*, *minimum_nights_mean*, *maximum_nights_mean* y *availability*. Sin embargo

al hacer la unión de los tres conjuntos de datos, fue posible identificar que la información agrupada de *calendar.csv* y *reviews.csv* ya estaba incluida en el dataset original, por lo que se optó por emplear únicamente *listings.csv* para el ejercicio.

El dataset de listings cuenta con 27,051 registros y 79 columnas, en distintos formatos de datos. Para el caso de las variables de fecha, se les aplicó ingeniería de variables para obtener la cantidad de días transcurridos desde la última fecha de *web scraping* realizada, con esto se obtuvieron columnas como *host_days_experience*, *days_since_first_review*, *days_since_last_review*, las variables originales fueron removidas del conjunto de datos.

Con la finalidad de mantener un estándar entre los tipos de datos se eliminaron símbolos como \$ y % para las variables de precios y ratios, respectivamente. Las variables categóricas se definieron en mayúsculas y las variables binarias se categorizaron con valores enteros 1 y 0.

Asimismo, se estandarizó el formato de las variables categóricas a mayúsculas. La variable *amenities*, que contiene la lista de amenidades por alojamiento, fue transformada en una nueva variable *n_amenities*, con el fin de reducir la dimensionalidad del conjunto de datos, considerando que algunos alojamientos presentaban hasta 50 amenidades distintas. Caso similar sucedió con *host_verifications*, la cual se transformó a la variable numérica *n_host_verifications*.

El último paso previo al análisis exploratorio de datos consistió en la eliminación de registros con valores nulos. Al examinar el dataset, se identificó que todas las variables de tipo score presentaban los mismos registros faltantes, los cuales representaban aproximadamente el 13 % del total de los datos. Para estos registros se optó por imputar por la mediana para no castigar o premiar alojamientos que no cuentan con información. A todas las demás variables con información faltante co-

mo *beds*, *price*, *bathrooms*, etc., se les aplicó un Imputador Iterativo.

Algunas variables como *price*, *minimum_nights* y *maximum_nights* presentan valores extremadamente alejados, por encima del percentil 99.




Figura 1: Distribución de la variable *price*.

En la figura 1 se observa que el rango de precios varía de 0 hasta los 900,000 pesos mexicanos. Sin embargo, la mayor parte de la densidad se concentra en valores bajos, por lo que para efectos de la visualización exploratoria se aplicó un recorte momentáneo en el percentil 95. Posteriormente, durante el tratamiento de outliers, se eliminaron de forma definitiva los registros por encima del percentil 99, lo que produce la nueva distribución mostrada a continuación.




Figura 2: Distribución de la variable *price*.

Dicha metodología se aplicó a otras variables posterior al análisis exploratorio de datos.

Análisis Exploratorio de Datos

En la Figura 3 se observa que la mayoría de los alojamientos oscila entre los \$500 y los \$1,500 pesos por noche, existiendo incluso lugares con precios por arriba de los \$3,000 por noche.




Figura 3: Frecuencia de precios sin valores extremos.

Otra variable de interés es la distribución por tipo de alojamiento. En la Ciudad de México, Airbnb cuenta con cuatro formatos: *Entire Home/Apt*, *Private Room*, *Shared Room* y *Hotel Room*. En este conjunto existen más departamentos completos disponibles para alquilar, seguidos por los cuartos privados.




Figura 4: Distribución por tipo de alojamiento.

Al emplear las dos variables anteriores podemos encontrar relaciones interesantes como las que se observan en la Figura 5, donde los cuartos de hotel son los que presentan una media de precio más alta, mientras que los cuartos compartidos son aquellos con precios más accesibles y con poca variación entre sus opciones. Los cuartos privados son ligeramente más accesibles que las casas/apartamentos; sin embargo presentan muchos datos dispersos por arriba de los \$2,500 pesos por noche.




Figura 5: Precio por tipo de alojamiento

Por su parte la capacidad (núm. personas) que un alojamiento puede aceptar afecta directamente al precio por noche. En la Figura 6 se observa que, de forma general, conforme más personas permite el alojamiento mayor es el precio por noche, siendo los alojamientos con una capacidad de 14 personas los que tienen una media de precios más elevada.




Figura 6: Impacto de la capacidad de personas en el Precio.

Con ayuda de las coordenadas proporcionadas en este conjunto de datos es posible observar la variación de precios de acuerdo con la zona de la Ciudad de México donde se acumulan la mayor cantidad de alojamientos con precios más elevados (Figura 7). A partir del siguiente gráfico podemos concluir que los alojamientos con precios más altos (círculos negros) se concentran cerca del centro, principalmente en la avenida Ejército Nacional, cerca del Museo Soumaya.




Figura 7: Mapa de precios y reseñas en la CDMX.

De igual forma, se observan precios elevados en la avenida Insurgentes. Los precios más bajos se pueden encontrar cerca del Estado de México y en el sur de la Ciudad de México. Por otra parte, la zona centro es la que presenta mayor cantidad de reseñas otorgadas (representadas por el tamaño del círculo), posiblemente propiciado por la cantidad de personas que han solicitado dichos hospedajes, siendo los alojamientos del centro los que mayor cantidad de reseñas tienen y, probablemente, mayor cantidad de visitantes también. Finalmente, se evaluó si el hecho de ser *Superhost* repercute en el precio. En la Figura 8 se observa que únicamente existe diferencia

en la media de los precios para el tipo casas o apartamentos, donde aquellos que cuentan con la distinción de *Superhost*, por lo general, tienen precios promedio más elevados.




Figura 8: Precios promedios por tipo de cuarto y superhost.

Previo al análisis de correlación se realizó el tratamiento de *outliers*, eliminando el percentil 99 para las variables con colas pesadas que presentaron un sesgo ≥ 2 ; las demás columnas que contenían valores atípicos se trataron mediante KNN.




Figura 9: Variables post tratamiento de outliers.

Con la finalidad de eliminar la multicolinea-

lidad entre variables numéricas, se desarrolló una matriz de correlación utilizando el coeficiente de Kendall. Este método resulta particularmente adecuado, ya que permite evaluar de manera consistente la relación entre variables numéricas tanto continuas como ordinales, sin asumir necesariamente una relación lineal estricta entre ellas. A partir de esta matriz, se estableció un punto de corte de $corr \geq 0,6$ con el objetivo de identificar pares de variables que presentan una asociación moderada o alta. Aquellas variables que superaron este umbral fueron analizadas con mayor detalle, considerando su relevancia dentro del modelo, con el fin de filtrar o eliminar las que pudieran introducir redundancia en la información y, por ende, problemas de multicolinealidad (Figura 10).




Figura 10: Correlación de variables numéricas

Con ayuda de la matriz de correlación, y aplicando un threshold de $corr \geq 0,6$. Fue posible encontrar 16 variables correlacionadas. En la Figura 11 es posible observar algunas de las variables que están correlacionadas, como *minimum_minimum_nights*, *maximum_minimum_nights*, *availability_60*, *availability_90*, *review_scores_accuracy* y *review_scores_value*.




Figura 11: Matriz de correlación Filtrada ($corr \geq 0,6$).

El último paso previo al modelado fue el escalado y la codificación. Para las variables numéricas se aplicó un escalamiento estándar, mientras que para las variables categóricas se realizó una codificación *One-Hot*.

Análisis de Componentes Principales

Si bien la matriz de correlación permitió identificar variables que podrían ser eliminadas, se optó por realizar un análisis de componentes principales para reducir la dimensionalidad del conjunto de datos y, posteriormente, comparar este resultado con el conjunto de datos original que contiene todas las variables limpiadas, escaladas y codificadas.

Para PCA se definió un umbral que permitiera explicar el 95 % de la varianza total del conjunto de datos, lo que permitió encontrar 32 componentes principales.

De igual forma, se definió una reducción a dos dimensiones para facilitar la visualización de los grupos obtenidos en el proceso de mode-




Figura 12: Número de componentes principales

lado.




Figura 13: Conjunto de datos en 2D

Modelado

Posterior a la limpieza y exploración de los datos, se realizaron cuatro modelos de aprendizaje no supervisado para determinar el número de clústeres adecuado. Se exploraron:

- K-Means:
 - Gráfico del codo.
 - Score de silueta.
- GMM:

- Gráfico del codo con AIC/BIC.
- Score de silueta.

- Clúster Jerárquico:

- Dendrograma.
- Score de silueta.

- DBSCAN:

- Curva Distancia K.

Cada método se aplicó a dos conjuntos de datos: el primero con el total de las columnas y el segundo luego de realizar la reducción de dimensiones mediante PCA.

K-Means

En resumen, los resultados obtenidos con y sin PCA son los siguientes:

- Con todas las variables:
 - Gráfico del codo: recomienda 8 grupos.
 - Score de silueta: recomienda 6 grupos con un score de 0.116.
- Con PCA:
 - Gráfico del codo: recomienda 6 grupos.
 - Score de silueta: recomienda 5 grupos con un score de 0.117.




Figura 14: Gráfico del codo con todas las variables




Figura 15: Score de silueta con todas las variables




Figura 16: Gráfico del codo con todas las variables PCA




Figura 17: Score de silueta con todas las variables PCA

GMM

En resumen, los resultados obtenidos con y sin PCA son los siguientes:

- Con todas las variables:
 - Gráfico del codo AIC/BIC: recomienda 5 grupos.
 - Score de silueta: recomienda 2 grupos con un score de 0.111.
- Con PCA:
 - Gráfico del codo AIC/BIC: no tiene punto de inflexión representativo.
 - Score de silueta: recomienda 2 grupos con un score de 0.08.

Número óptimo de clusters GMM - Criterios de Información (AIC / BIC)




Figura 18: Gráfico del codo con todas las variables (AIC).

Número óptimo de clusters - Silueta (GMM)




Figura 19: Score de silueta con todas las variables.




Figura 20: Gráfico del codo con PCA (AIC).




Figura 21: Score de silueta con PCA.

Clúster Jerárquico

En resumen, los resultados obtenidos con y sin PCA son los siguientes:

- Con todas las variables:
 - Dendrograma: recomienda 6 grupos.
 - Score de silueta: recomienda 3 grupos con un score de 0.118.
- Con PCA:
 - Dendrograma: recomienda 6 grupos.
 - Score de silueta: recomienda 6 grupos con un score de 0.08.




Figura 22: Dendrograma con todas las variables.




Figura 23: Score de silueta con todas las variables.




Figura 24: Dendrograma con PCA.




Figura 25: Score de silueta con PCA.

DBSCAN

En resumen, los resultados obtenidos con PCA son los siguientes:

- Con PCA (Varianza Explicada 95 %):
 - Curva K-Distance: recomienda 6 grupos.

Curva K-Distance (min_samples=32)




Figura 26: Gráfico K-Distancias con PCA

Visualización en 2D

De acuerdo con los resultados obtenidos, se realizan visualizaciones en dos dimensiones con el número de clústeres óptimo por cada modelo.




Figura 27: K-Means con 6 clústeres en 2D.




Figura 28: GMM con 5 clústeres en 2D.




Figura 29: Clúster Jerárquico con 3 clústeres en 2D.




Figura 30: DBSCAN con 1 clúster en 2D.

Se observa una distribución más uniforme con los 3 grupos obtenidos mediante Clúster Jerárquico.

Perfilamiento

Tras evaluar cuatro algoritmos (K-Means, GMM, Clúster Jerárquico y DBSCAN) en espacios de dimensionalidad original y reducida (PCA), se seleccionó el modelo de Clúster Jerárquico con todas las variables y $k=3$. Si bien gran parte de los modelos mostraron una clasificación óptima de 6 grupos, el Clúster Jerárquico obtuvo el score de silueta más alto (0.118) con 3 divisiones. Esto permite una mejor distribución de los datos al graficarlos en baja dimensionalidad y facilita el desarrollo de estrategias comerciales más accionables para el mercado de Airbnb en la CDMX.

Algunas métricas relevantes por grupo son las siguientes:

Cuadro 1: Perfil y métricas de los clústeres.

Clúster	0	1	2
price	1,245	1,597	1,347
accommodates	2.92	4.11	2.48
bedrooms	1.4	1.72	1.47
beds	1.72	2.26	1.6
min_nights	2.04	1.6	22.83
max_nights	456.63	532.92	449.9
availability_365	226.01	250.8	179.3
rvw_scores_rating	4.78	4.82	4.82
rvw_scores_value	4.75	4.79	4.76
rvws_per_month	1.12	2.95	0.26
number_of_rvws	32.77	111.08	12.72
host_list_count	8.38	41.72	6.00
n_amenities	13.8	11.63	13.6
%_is_superhost	33.7	57.7	22.6
%_ins_bookable	37.9	53.9	17.5
n_listings	18,308	4,915	610

De igual forma, con ayuda de las coordenadas es posible graficar los grupos obtenidos dentro del contorno de la Ciudad de México.




Figura 31: Mapa de grupos de alojamientos en la CDMX.

Clúster 0: Mercado Base

Representa el grueso de la plataforma de Airbnb en la CDMX. Se trata de anfitriones individuales o semiprofesionales con 1 o 2 propiedades, que operan en zonas residenciales fuera del centro. Es el “promedio” del mercado en casi todo: precio medio, capacidad media y ocupación moderada.

Presenta un precio de \$1,245 MXN por noche y una capacidad de 2.92 personas. Cada anfitrión administra en promedio 8 alojamientos, con 1.12 reseñas por mes y 33 reseñas acumuladas (rotación baja-media). Solo el 33.7% son *Superhost* y el 37.9% cuenta con reserva inmediata (*instant_bookable*). Además, tiene mejor dotación de amenities que el clúster 1 (13.8 frente a 11.63).

Se encuentran distribuidos por toda la CDMX, probablemente con una presencia fuerte en colonias residenciales de clase media.




Figura 32: Clúster 0: Mercado Base.

Clúster 1: Alojamientos Premium

Anfitriones profesionales o empresas de gestión inmobiliaria que operan cantidades considerables de alojamientos en zonas céntricas y turísticas. Es el segmento de mayor valor por alojamiento y el más rentable para Airbnb.

Cuentan con un precio premium de \$1,597 MXN por noche y una mayor capacidad: 4.11 personas y 1.72 recámaras en promedio (departamentos completos). Su operación es más profesional, dado que cada anfitrión administra en promedio 41.7 alojamientos, lo que representa cinco veces más que el clúster 0. Presentan más reseñas acumuladas (111.08) y 2.95 reseñas por mes, lo que indica una alta rotación. De igual forma, el 57.7% son *Superhost* y el 53.9% pueden ser rentados al instante. Además, tienen una alta disponibilidad (250 días al año).

Se encuentran principalmente en el centro turístico de la Ciudad de México, en colonias como Roma, Condesa, Polanco, Centro Histórico y Juárez. Tienen los valores de *minimum_nights* más bajos (1.6), lo que confirma que están optimizados para estancias cortas de turistas y se traduce en máxima rotación y mayor número de reseñas.



Figura 33: Clúster 1: Alojamientos Premium.

Clúster 2: Estancias Largas

Es un grupo de alojamientos muy diferenciado, orientado a rentas mensuales o corporativas. Su rasgo más distintivo dentro del conjunto de datos es el mínimo de noches (*minimum_nights* = 22.83). Cuentan con solo 0.26 reseñas por mes y 12.72 acumuladas.

Tienen baja disponibilidad (179 días), lo que genera largos bloqueos por inquilinos prolongados. El precio medio es de \$1,347 por noche, que no resulta tan alto, pero dado que suelen ser estancias prolongadas, el costo mensual puede ser muy elevado. Los anfitriones administran una baja cantidad de alojamientos (6 en promedio). Solo el 17.5% es *instant_bookable*, lo que indica que la mayoría de los alojamientos se encuentran ocupados. Mantienen una calificación alta (4.82) a pesar de su baja rotación; es decir, cuando reciben un huésped, lo hacen bien.

Los alojamientos se encuentran dispersos por la ciudad, con presencia en zonas atractivas para personas que llegan de fuera para rentas largas, trabajadores y empresas, entre otros.




Figura 34: Clúster 2: Estancias Largas.

Conclusión

El análisis geográfico revela que la segmentación no es solo estadística, sino también espacialmente significativa: el clúster 1 se concentra en el núcleo turístico de la CDMX (Roma, Condesa, Polanco y Centro), lo que explica simultáneamente sus tres rasgos principales: mayor precio, menor *minimum_nights* (optimizado para el turismo de paso) y mayor número de reseñas (máxima rotación). Es-

to valida que el *clustering* capturó dinámicas reales del mercado y no solo correlaciones estadísticas.

Referencias

- [1] Google (s.f). ¿Qué es el aprendizaje automático (AA)? Obtenido de: <https://cloud.google.com/learn/what-is-machine-learning?hl=es-419>. Fecha de recuperación: (23/09/2026).
- [2] IBM (s.f). ¿Qué es el aprendizaje no supervisado? Obtenido de: <https://www.ibm.com/mx-es/think/topics/unsupervised-learning>. Fecha de recuperación: (23/09/2026).

Anexos: Diccionario de Variables

Variable	Descripción
host_response_rate	Porcentaje de solicitudes a las que el anfitrión responde.
host_acceptance_rate	Porcentaje de solicitudes de reserva que el anfitrión acepta.
host_total_listings_count	Número total de anuncios publicados por el anfitrión.
host_is_superhost	Indica si el anfitrión tiene la distinción de Superhost (t/f).
latitude	Coordenada geográfica de latitud del alojamiento (WGS84).
longitude	Coordenada geográfica de longitud del alojamiento (WGS84).
property_type	Tipo de propiedad declarado por el anfitrión.
room_type	Tipo de alojamiento: casa/apto completo, cuarto privado, compartido u hotel.
accommodates	Capacidad máxima de huéspedes del alojamiento.
bathrooms	Número de baños del alojamiento.
bedrooms	Número de habitaciones del alojamiento.
minimum_nights	Mínimo de noches requerido para reservar.
maximum_nights	Máximo de noches permitido para una reserva.
minimum_maximum_nights	Valor mínimo de noches máximas según el calendario (próximos 365 días).
availability_30	Días disponibles del alojamiento en los próximos 30 días.
availability_365	Días disponibles del alojamiento en los próximos 365 días.
number_of_reviews	Número total de reseñas del alojamiento.
number_of_reviews_ltm	Reseñas recibidas en los últimos 12 meses.
number_of_reviews_l30d	Reseñas recibidas en los últimos 30 días.
review_scores_rating	Calificación general del alojamiento.
review_scores_cleanliness	Calificación de limpieza otorgada por los huéspedes.
review_scores_checkin	Calificación del proceso de check-in.
review_scores_communication	Calificación de la comunicación con el anfitrión.
review_scores_location	Calificación de la ubicación del alojamiento.
...	...
price	Variable objetivo: precio por noche en pesos mexicanos (MXN).